Разложение ошибки на смещение и разброс.

Пицик Харитон

Клуб ML

Математическое ожидание

Рассмотрим случай регрессии с `MSE`. Пусть наша модель учится предсказывать зависимость вида

$$y = f(x) + \varepsilon$$

Где ε — некоторый шум

Математическое ожидание

В качестве шума в данных может быть:

Математическое ожидание

В качестве шума в данных может быть:

1. Неточность измерительных приборов;

Математическое ожидание

В качестве шума в данных может быть:

1. Неточность измерительных приборов;

2. Допустимая погрешность;

Математическое ожидание

В качестве шума в данных может быть:

1. Неточность измерительных приборов;

2. Допустимая погрешность;

3. Плохой набор данных.

Математическое ожидание

На основе одной ошибки сложно сказать, хороша ли наша модель или нет. Хотелось бы увидеть `MSE` не на конкретной выборке, а на всей, генеральной выборке.

Математическое ожидание

На основе одной ошибки сложно сказать, хороша ли наша модель или нет. Хотелось бы увидеть `MSE` не на конкретной выборке, а на всей, генеральной выборке.

Этого можно добиться, используя математическое ожидание:

$$MSE = \mathbb{E}[(y - a(x))^2]$$

Разложение ошибки

Шаг 1: Добавим магическое нулевое слагаемое

Возьмём исходную ошибку и добавим к ней $\mathbb{E}[\hat{y}] - \mathbb{E}[\hat{y}]$ (то есть ноль):

Шаг 1: Добавим магическое нулевое слагаемое

Возьмём исходную ошибку и добавим к ней $\mathbb{E}[\hat{y}] - \mathbb{E}[\hat{y}]$ (то есть ноль):

$$\mathbb{E}\big[(y - \hat{y})^2\big] = \mathbb{E}\big[(y - \mathbb{E}[\hat{y}] + \mathbb{E}[\hat{y}] - \hat{y})^2\big]$$

Шаг 1: Добавим магическое нулевое слагаемое

Возьмём исходную ошибку и добавим к ней $\mathbb{E}[\hat{y}] - \mathbb{E}[\hat{y}]$ (то есть ноль):

$$\mathbb{E}\big[(y - \hat{y})^2\big] = \mathbb{E}\big[(y - \mathbb{E}[\hat{y}] + \mathbb{E}[\hat{y}] - \hat{y})^2\big]$$

Переупорядочим:

$$\mathbb{E}\big[(y - \hat{y})^2\big] = \mathbb{E}\big[((y - \mathbb{E}[\hat{y}]) + (\mathbb{E}[\hat{y}] - \hat{y}))^2\big]$$

Шаг 2: Раскроем ФСУ

Шаг 2: Раскроем квадрат суммы

По формуле $(a+b)^2 = a^2 + 2ab + b^2$:

Шаг 2: Раскроем ФСУ

По формуле $(a+b)^2 = a^2 + 2ab + b^2$:

$$\mathbb{E}\big[((y - \mathbb{E}[\hat{y}]) + (\mathbb{E}[\hat{y}] - \hat{y}))^2\big]$$

$$= \mathbb{E}\big[(y - \mathbb{E}[\hat{y}])^2 + 2(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y}) + (\mathbb{E}[\hat{y}] - \hat{y})^2\big]$$

Шаг 3: Разделим математическое ожидание (по линейности)

У математического ожидания есть одно важное свойство:
$\mathbb{E}[a + b + c] = \mathbb{E}[a] + \mathbb{E}[b] + \mathbb{E}[c]$.

Шаг 3: Разделим математическое ожидание (по линейности)

У математического ожидания есть одно важное свойство:
$\mathbb{E}[a + b + c] = \mathbb{E}[a] + \mathbb{E}[b] + \mathbb{E}[c]$.

Применим его:

$$\mathbb{E}\big[(y - \hat{y})^2\big] = \mathbb{E}\big[(y - \mathbb{E}[\hat{y}])^2\big] + \mathbb{E}[2(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y})] + \mathbb{E}\big[(\mathbb{E}[\hat{y}] - \hat{y})^2\big]$$

Шаг 4: Второе слагаемое

Извлечём константу за знак ожидания:

$$2 \cdot \mathbb{E}[(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y})]$$

Шаг 4: Второе слагаемое

Извлечём константу за знак ожидания:

$$2 \cdot \mathbb{E}[(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y})]$$

Ключевое наблюдение:

- y — это истинное значение (константа, не зависит от модели)
- $\mathbb{E}[\hat{y}]$ — это тоже константа (мы усредняем по всем возможным моделям)

Шаг 4: Второе слагаемое

Извлечём константу за знак ожидания:

$$2 \cdot \mathbb{E}[(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y})]$$

Ключевое наблюдение:

- y — это истинное значение (константа, не зависит от модели)
- $\mathbb{E}[\hat{y}]$ — это тоже константа (мы усредняем по всем возможным моделям)

Поэтому $(y - \mathbb{E}[\hat{y}])$ — просто число, которое можно вынести за знак математического ожидания:

$$2(y - \mathbb{E}[\hat{y}]) \cdot \mathbb{E}[\mathbb{E}[\hat{y}] - \hat{y}]$$

Шаг 4: Второе слагаемое

Теперь посчитаем $\mathbb{E}[\mathbb{E}[\hat{y}] - \hat{y}]$:

$$\mathbb{E}[\mathbb{E}[\hat{y}] - \hat{y}] = \mathbb{E}[\mathbb{E}[\hat{y}]] - \mathbb{E}[\hat{y}]$$

Применим свойство, что $\mathbb{E}[\text{константа}] = \text{константа}$:

$$\mathbb{E}[\mathbb{E}[\hat{y}]] = \mathbb{E}[\hat{y}]$$

Поэтому:

$$\mathbb{E}[\mathbb{E}[\hat{y}] - \hat{y}] = \mathbb{E}[\hat{y}] - \mathbb{E}[\hat{y}] = 0$$

Шаг 5: Упростим оставшиеся два члена

После обнуления перекрёстного члена остаются только первый и третий члены:

$$\mathbb{E}\big[(y-\hat{y})^2\big] = \mathbb{E}\big[(y-\mathbb{E}[\hat{y}])^2\big] + \mathbb{E}\big[(\mathbb{E}[\hat{y}]-\hat{y})^2\big]$$

Шаг 6: Финальная формула

Собрав всё вместе:

$$\mathbb{E}\big[(y - \hat{y})^2\big] = (y - \mathbb{E}[\hat{y}])^2 + \mathrm{Var}(\hat{y})$$

Если обозначить $\mathrm{Bias} = \mathbb{E}[\hat{y}] - y$, то:

$$\mathbb{E}\big[(y - \hat{y})^2\big] = \mathrm{Bias}^2 + \mathrm{Variance} + \mathrm{Irreducible\ Error}$$

Пояснения к разложению

Пояснения к разложению

$$\mathbb{E}[(y - \hat{y})^2] = \text{Bias}^2 + \text{Variance} + \text{Irreducible Error}$$

- Bias — смещение;
- Variance — разброс;
- Irreducible Error — шум.

Пояснения к разложению

$$\mathbb{E}[(y - \hat{y})^2] = \mathrm{Bias}^2 + \mathrm{Variance} + \mathrm{Irreducible\ Error}$$

Bias означает то, насколько наша модель систематически ошибается. То есть, это мера ошибки, которую модель будет допускать гарантированно в силу недообучения.

Пояснения к разложению

$$\mathbb{E}[(y - \hat{y})^2] = \text{Bias}^2 + \text{Variance} + \text{Irreducible Error}$$

Variance означает, насколько наша модель будет выдавать разные результаты, если будет меняться набор данных. Высокий разброс свидетельствует о переобучении модели.

Пояснения к разложению

$$\mathbb{E}[(y - \hat{y})^2] = \text{Bias}^2 + \text{Variance} + \text{Irreducible Error}$$

Irreducible Error означает шум в данных и отражает ошибку, которую невозможно избежать ни при каких условиях. Так или иначе, даже самая идеальная модель будет гарантированно допускать ошибку. А величина этой ошибки зависит от качества самих данных.

Странная ситуация…

Выходит, что если мы будем упрощать модель, то ошибка будет увеличиваться.

Странная ситуация…

Выходит, что если мы будем упрощать модель, то ошибка будет увеличиваться.

Но и выходит, что если мы будем усложнять модель, то ошибка тоже будет увеличиваться?

Странная ситуация…

Выходит, что если мы будем упрощать модель, то ошибка будет увеличиваться.

Но и выходит, что если мы будем усложнять модель, то ошибка тоже будет увеличиваться?

Одной из главных задач машинного обучения является поиск компромисса между смещением и разброса, что в литературе ещё иногда называют `bias-variance tradeoff`.

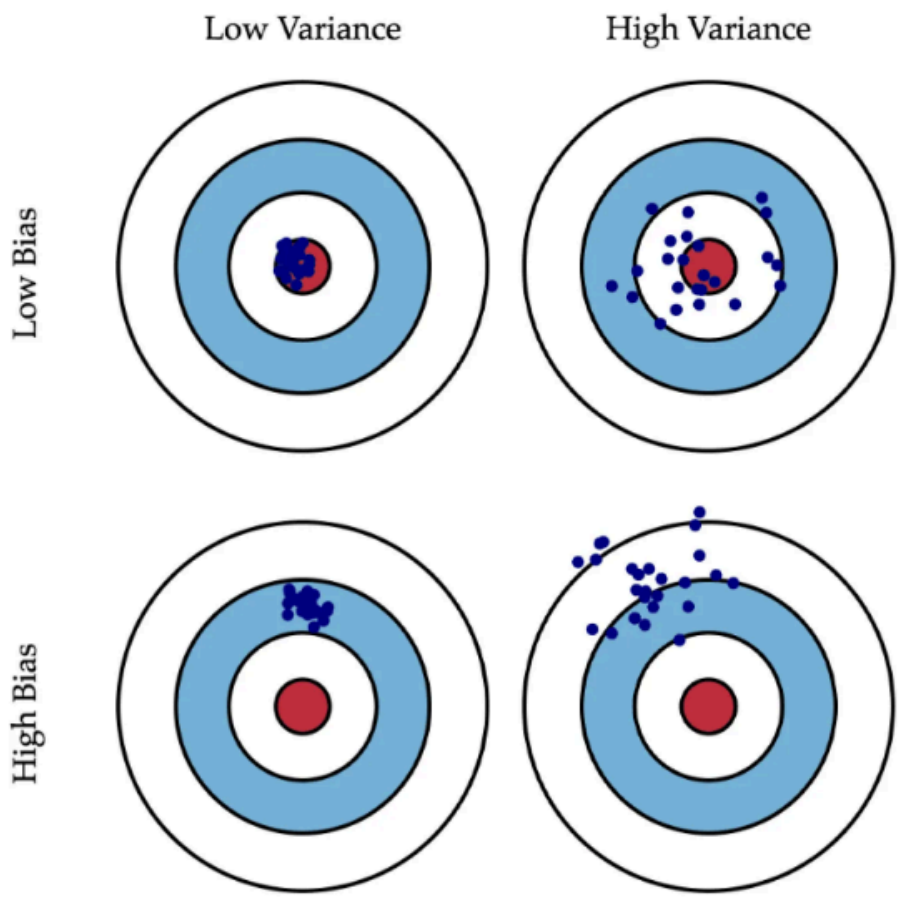
Low Variance
High Variance
Low Bias
High Bias

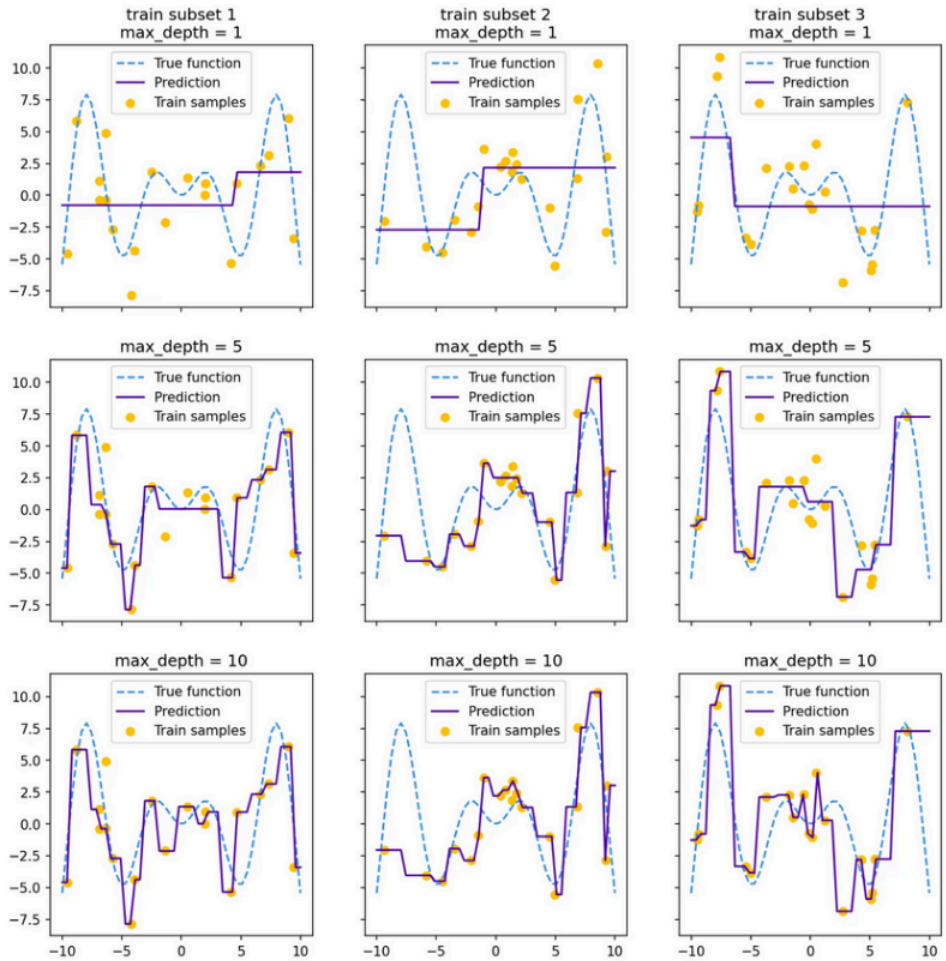
train subset 1
max_depth = 1
train subset 2
max_depth = 1
train subset 3
max_depth = 1
max_depth = 5
max_depth = 5
max_depth = 5
max_depth = 10
max_depth = 10
max_depth = 10
True function
Prediction
Train samples
10.0
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10
−5
0
5
10