Лекция 6. SVM

В этой лекции мы покажем иной подход к задаче классификации, и постараемся ответить на насущный вопрос — а зачем нам нужен ещё какой-то подход, ведь казалось бы, итак уже есть логистическая регрессия?

Прежде чем перейти к сути метода опорных векторов, неплохо было бы вспомнить несколько базовых понятий, на которых он строится. Речь идёт об *отступе* (margin) и о *верхней оценке*, с помощью которой алгоритм принимает решение о принадлежности точки к тому или иному классу. Эти концепции являются фундаментальными для понимания того, почему SVM работает именно так, а не иначе, и почему он демонстрирует хорошую обобщающую способность на новых данных.

Разделяющая гиперплоскость

Вообще, в классификации принято разделять типы выборок на *линейно разделимую* и *линейно неразделимую*. Из названия должно быть (надеюсь) понятно, что это означает, но давайте на всякий случай взглянем на следующее изображение:

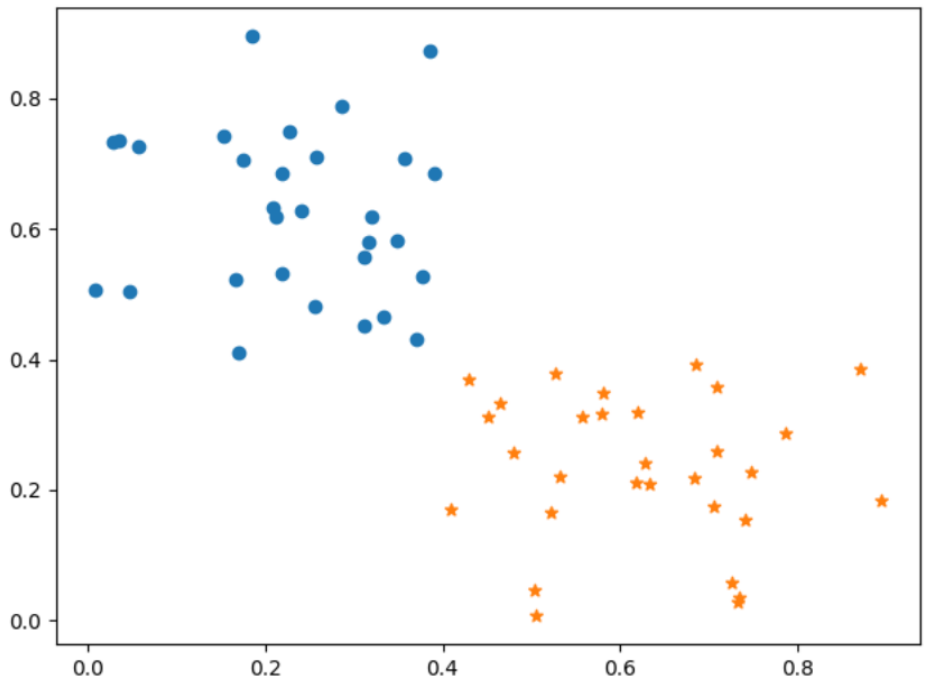

Как можно увидеть, через данную выборку очевидным образом можно провести прямую, которая идеально разделит наши данные. Соответственно, линейно неразделимым случаем называется обратное.

Однако здесь появляется разумный вопрос — как нетрудно заметить, таких идеально разделяющих прямых можно построить бесконечно много, неужели они все будут считаться идеальными? И тут появляется следующий пример:

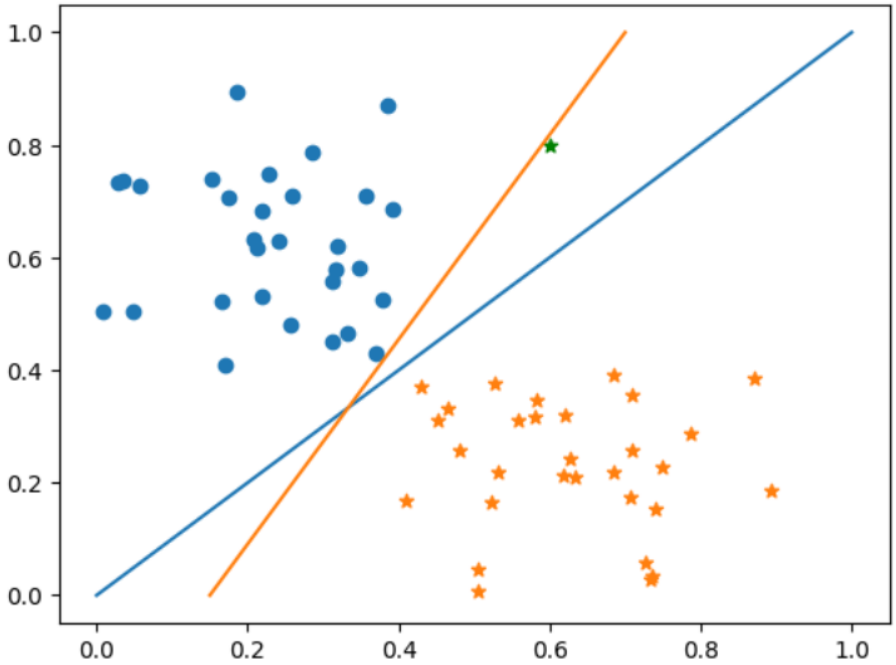

Глазами видно, что оранжевая прямая хуже синей, но почему?

Дело в том, что оранжевая прямая вносит какие-то дополнительные объяснения данных. Например посмотрите на зелёную точку, которая интуитивно, очевидно, не должна принадлежать классу оранжевых звёздочек, но в силу такого построения она ему принаджелит. Задача сводится к построению не только разделяющей гиперплоскости, но и чтобы она была корректной. Тут и выручает SVM (Метод Опорных Векторов).

Здесь мы уже более явно работаем с margin, и явно стараемся максимизировать расстояние от точек до гиперплоскости (т.к. с точки зрения геометрии, такая прямая действительно будет лучшей для наших задач). Однако у обычного margin в этом смысле есть определённая проблема...

Геометрический отступ

В классическом отступе, как мы ранее упомянали, не происходит нормирования расстояния, т.е. по факту это «расстояние до гиперплоскости» по факту может иметь нереалистичное значние. Мы его использовали, т.к. это расстояние оказалось наиболее интуитивно понятным и легко интегрируемым в дальнейшие модели.

Для устранения зависимости от масштаба параметров вводится более устойчивая мера – *геометрический отступ*. Он определяется следующим образом:

$$\gamma_i^{(\text{geom})} = \frac{M}{\|w\|}.$$

То есть по факту, теперь мы всё-таки берём более реальное расстояние. В контексте SVM нам это особенно пригодится.

Нормировка масштаба и постановка задачи

Далее мы ставим перед собой следующую задачу:

$$\min M = 1.$$

А теперь тяжёлый для осознания трюк: мы полагаем, что минимальный допустимый margin будет единицей. Ранее мы упомянали формулу геометрического отступа, и теперь можем составить задачу его минимизации:

$$\min \frac{M}{||w||}$$

Смотря на условие выше, получится

$$\min \frac{M}{||w||} = \frac{1}{||w||}$$

Величину $\frac{2}{||w||}$ называют шириной разделяющей гиперплоскости.

Здесь остановимся немного подробнее: максимизацией геометрического отступа мы хотим добиться того, чтобы расстояние от точек до гиперплоскости было как можно больше. Это означает бОльшую уверенность классификатора в предсказании.

Соответственно, здесь появляется первое отличие от логистической регрессии. Она делала упор на подсчёт вероятностей, а метод опорных векторов позволяет делать наиболее уверенные классификации.

Рассмотрим самый простой пример для наглядности. Пусть у нас всего два объекта в одномерном пространстве: $x_1 = +1$ с меткой $y_1 = +1$ и $x_2 = -1$ с меткой $y_2 = -1$. Возьмём простейший классификатор с параметрами $w = 1$, $b = 0$. Тогда функция оценки будет $f(x) = x$, а разделяющая граница – точка

$x = 0$. Вычислим функциональные отступы:

$$y_1(wx_1 + b) = 1 \cdot (1 \cdot 1 + 0) = 1, \qquad y_2(wx_2 + b) = (-1) \cdot (1 \cdot (-1) + 0) = 1.$$

Оба объекта классифицированы правильно и находятся на одинаковом функциональном отступе, равном 1. Геометрический отступ (расстояние) для каждого из них составит $1/|w| = 1$. В данном случае любая другая разделяющая граница, расположенная между -1 и +1, также будет корректно классифицировать точки, но её геометрический отступ до ближайшей точки будет меньше. Например, если сместить границу в точку $x = 0.5$, то расстояние до ближайшей точки $x_1 = 1$ станет 0.5. SVM же выберет именно ту границу, которая максимизирует этот минимальный отступ, то есть точку $x = 0$.

Этот пример наглядно иллюстрирует, что задача SVM заключается не просто в нахождении любой разделяющей гиперплоскости, а в выборе такой, которая обеспечивает наибольший зазор между классами, проходя по наиболее безопасному, удалённому от данных участку.

Линейно-разделимый и линейно-неразделимый случаи

Ранее мы уже успели познакомиться с этими понятиями, и самое время рассказать зачем.

Как мы уже поняли, задача SVM заключается в том, чтобы попытаться максимизировать расстояние от разделяющей гиперплоскости до точек каждого из классов. Но тут возникает закономерный вопрос — а что делать при линейно неразделимом случае?

И тут мы плавно переходим к факту, что на самом деле, стратегии для обоих этих случаев разная, и далее мы будем выводить их для линейно разделимого и линейно неразделимого случаев.

Линейно-разделимый случай

Пусть у нас есть обучающая выборка

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n, \quad y_i \in \{-1, +1\}.$$

Мы говорим, что эта выборка *линейно разделима*, если существует такая гиперплоскость

$$w^\top x + b = 0,$$

которая полностью отделяет точки одного класса от точек другого, то есть выполняются неравенства

$$y_i(w^\top x_i + b) > 0 \quad \forall i = 1, \ldots, n.$$

Среди всех гиперплоскостей, удовлетворяющих этому условию, метод опорных векторов выбирает ту, для которой норма вектора весов минимальна:

$$\max_w \frac{2}{||w||} \quad \text{при условии} \quad y_i(w^\top x_i + b) \geq 1, \ \forall i.$$

Говоря проще — мы хотим максимизировать воображаемую ширину разделяющей гиперплоскости при условии, что она по прежнему корректно классифицирует все объекты.

Давайте в одну систему соберём все нужные условия:

$$\begin{cases} \|w\| \to \min \\ \text{y}_i(\langle w, x\rangle + b) \geq 0 \text{ Требование корректной классификации} \\ |\langle w, x\rangle + b| \geq 1 \text{ Ранее поставленное требование} \end{cases}$$

Давайте попробуем упростить эту систему. Заметим, что второе и третье условия уж слишком похожи. Мы можем подставить третье во второе и сказать, что всё это не меньше единицы, т.к. $y_i \in \{-1, 1\}$, и в таком случае наше требование корректной классификации не нарушится.

$$y_i(\langle w, x\rangle + b) \geq 1$$

Вставим это в систему:

$$\begin{cases} \|w\| \to \min \\ \text{y}_i(\langle w, x\rangle + b) \geq 1 \text{ Требование корректной классификации} \end{cases}$$

Так формулируется решение задачи с использованием **жёсткого зазора (hard margin SVM)** — базовый вариант метода, применимый к идеально разделимым данным.

Линейно-неразделимый случай

К сожалению, реальность редко бывает столь благосклонной. В большинстве реальных задач данные оказываются *линейно неразделимыми*: классы частично пересекаются, в выборке есть шум, выбросы и т.д.

В этом случае не существует пары параметров (w, b), для которых все точки удовлетворяли бы неравенству $y_i(w^\top x_i + b) > 0$. Сколько бы мы ни пытались повернуть или сдвинуть гиперплоскость, всегда найдутся точки, которые окажутся «по неправильную сторону».

Идея заключается в том, чтобы разрешить некоторым точкам нарушать ограничение $y_i(w^\top x_i + b) \geq 1$, но ввести за это «штраф». Для этого в модель добавляются специальные неотрицательные переменные ξ_i, называемые *переменными послабления* (англ. *slack variables*). Каждая из них показывает, насколько сильно нарушено требование разделимости для соответствующей точки. Этими

переменными мы намерены ослаблять наше «модифицированное» условие:

$$y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Если $\xi_i = 0$, точка классифицирована корректно и находится за пределами зазора. Если $0 < \xi_i < 1$, она попадает внутрь зазора, но остаётся на правильной стороне гиперплоскости. Если же $\xi_i > 1$, классификатор ошибся: точка оказалась не только в зазоре, но и с другой стороны разделяющей границы.

Однако у этого проблема есть одна, довольно неочевидная проблема: при $\xi \to \infty$ появляется решение $w = 0$. Разумеется, с такими весами модель ничему и не научится, поэтому нужно что-то придумывать.

А придумаем мы вот что: в качестве условия добавим, что мы хотим минимизировать сумму ξ. В таком случае, в силу постановки задачи мы просто не сможем ставить сколь угодно большие ослабления условия.

Обычно сумма домножается на некоторый коэффициент $C > 0$, который задаёт *цену ошибки*.

$$\max_{w,\xi} \frac{2}{\|w\|} + C \sum_{i=1}^{n} \xi_i \quad \text{при условиях} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Теперь нам предстоит перейти к *безусловному виду*, где эти условия будут подразумеваться самой формулой.

Для первого условия выразим ξ:

$$\xi \geq 1 - y_i(\langle w, x \rangle + b)$$

Заметим, что в совокупности со вторым условием, ξ должно быть не меньше нуля и числа $1 - M$. Значит, оно равно

$$\max(0, 1 - M)$$

Теперь мы можем записать задачу в безусловном виде. Сразу запишем в привычном виде — функции потерь принято минимизировать, а я напомню, что

мы выводим именно её:

$$||w|| + C\frac{1}{\ell}\sum_{i=1}^{\ell}\max(0, 1 - M) \to \min_{w}$$

Таким образом выводится задача для **мягкого зазора (soft margin SVM)**.

Идея SVM: зачем он нужен и почему не хватает логистической регрессии

После детального рассмотрения линейно-разделимых и неразделимых случаев естественным образом возникает фундаментальный вопрос о месте метода опорных векторов в современном арсенале алгоритмов машинного обучения. Действительно, когда существует такая классическая и хорошо изученная модель как логистическая регрессия, зачем разрабатывать ещё один метод для решения задачи бинарной классификации?

Различие двух подходов

Если внимательно проанализировать теоретические основы логистической регрессии и метода опорных векторов, становится ясно, что хотя оба метода решают задачу классификации, они исходят из совершенно различных предпосылок и оптимизируют разные целевые функции.

Логистическая регрессия нацелена на максимизацию правдоподобия наблюдаемых данных. Её математический аппарат строится вокруг моделирования вероятности принадлежности объекта к положительному классу с помощью сигмоидной функции. Формально это выражается как $P(y = +1|x) = \sigma(w^\top x + b)$. (вероятность положительного класса на текущем объекте x). Процесс обучения в этом случае сводится к максимизации логарифмического правдоподобия или, что эквивалентно, минимизации логистической функции потерь.

Метод опорных векторов, напротив, реализует принципиально иную философию. Вместо того чтобы стремиться к идеальной классификации всех точек, SVM фокусируется исключительно на тех наблюдениях, которые находятся ближе всего к границе между классами — так называемых опорных векторах. Основная цель алгоритма — не минимизация ошибки на всей выборке, а максимизация зазора между классами, то есть расстояния от разделяющей гиперплоскости до ближайших точек каждого класса.

Почему максимизация зазора важна?

Максимизация зазора между классами — это не просто математическая элегантность или эстетическое предпочтение. Данный принцип имеет глубо-

кое теоретическое обоснование и важные практические следствия, связанные с обобщающей способностью модели.

Логистическая регрессия, стремясь правильно классифицировать все точки без исключения, может существенно изменить положение разделяющей прямой, чтобы учесть выбросы. В результате граница решения окажется расположенной близко к основной массе точек обоих классов, что потенциально ухудшит обобщающую способность модели на новых данных. В этом случае SVM показывает себя значительно устойчивее на выбросах, т.к. ориентируется в основном на опроные векторы.

И это всё приводит к занятной мысли — обычно, у SVM базовые метрики (F-мера, $precision$, $recall$...) выше, чем у логистической регрессии. С другой стороны, логистическая регрессия позволяет корректно работать с вероятностями. Модель подбирается по нужде, и мы ещё успеем убедиться, что не существует универсального алгоритма, который способен решать задачу лучше всех остальных.