Лекция 9. Разложение ошибки на смещение и разброс

На практике регулярно происходит так, что одна конкретная модель (или класс моделей) показывает себя лучше других. В некоторых случаях бывает так, что линейная модель показывает себя лучше, чем решающие деревья, хотя мы недавно обсуждали разноплановость и эффективность дереьев. Но почему так происходит? Есть ли какое-то обоснование тому, как подбираются модели для решения задачи?

В рамках данной лекции мы рассмотрим одну из наиболее важных тем, пожалуй, всего машинного обучения. Мы покажем, как можно интерпретировать ошибку модели на данных, и как мы можем контроллировать этот процесс.

Математическое ожидание

Для начала, хотелось бы понять — а зачем это всё надо? Видите ли, разные выборки имеют разную природу, и заранее точно мы не можем знать, какую модель будет *корректно* применить для получения хороших результатов. Соответственно, предлагается на основе ошибки, которая допускает модель, вывести дополнительные предположения о том, насколько хорошо справляется наша модель.

Например, рассмотрим случай регрессии с MSE. Также для простоты представим, что наша модель учится предсказывать зависимость вида

$$y = f(x) + \epsilon$$

Где ϵ — некоторый шум, искуственно добавленный в данные. В реальной жизни этим шумом может быть

- Недостаточная точность измерительного прибора;
- Плохой набор данных, на основе которого невозможно в точности предсказать целевую переменную;
- Погрешность;
- ...

Как мы уже и обсуждали на одном из первых занятий, на основе одного лишь

$$(a(x) - y)^2$$

нельзя сделать выводы о том, насколько хороша построенная модель. Но можем ли мы как-то сделать так, чтобы какие-то выводы всё таки было возможно сделать?

Ну например, хотелось бы в модели смотреть не на конкретный объект, а на всю выборку, откуда этот объект поступил:

$$a(x) = a(x, X)$$

Пока представим, что мы как-то переоборудовали нашу модель так, чтобы она на вход ещё принимала всю выборку.

И здесь мы подходим к самому интересному: хотелось бы с такой моделью, которую мы построили ранее, увидеть MSE на *всех возможных данных* (не только на тех, которые даны в X, а вообще на всевозможных таких данных). Идея в том, что с точки зрения статистики, X является лишь частью так называемой *генеральной выборки*. Но как нам получить доступ ко всей, *генеральной* выборке?

Тут мы плавно переходим к понятию *математического ожидания*. Давайте сразу взглянем на формулу:

$$MSE = \mathbb{E}[(y - a(x, X))^2]$$

Математическое ожидание обозначается буквой $\mathbb{E}$, и в контексте этой формулы означает: «Если мы будем повторять этот процесс (строить модель, делать предсказание, считать ошибку) много раз на разных данных, какое среднее значение ошибки мы получим?»

Математическое ожидание — это инструмент, который позволяет нам перейти от конкретных ошибок к общей картине. Вместо того чтобы говорить «в этот раз ошибка 0.2», мы говорим «в среднем, учитывая все возможные варианты обучающих данных, ошибка составляет...».

Разложение на смещение и разброс

Мы получили ошибку:

$$MSE = \mathbb{E}[(y - a(x, X))^2]$$

которую и собираемся «раскладывать».

Теперь нам нужно понять, как эта ошибка $\mathbb{E}[(y - a(x, X))^2]$ (для удобства, будем заменять $a(x, X)$ на $\hat{y}$) разбивается на компоненты.

Шаг 1: Добавим магическое нулевое слагаемое

Возьмём исходную ошибку и добавим к ней $\mathbb{E}[\hat{y}] - \mathbb{E}[\hat{y}]$ (то есть ноль):

$$\mathbb{E}[(y - \hat{y})^2] = \mathbb{E}[(y - \mathbb{E}[\hat{y}] + \mathbb{E}[\hat{y}] - \hat{y})^2]$$

Переупорядочим:

$$\mathbb{E}[(y - \hat{y})^2] = \mathbb{E}[((y - \mathbb{E}[\hat{y}]) + (\mathbb{E}[\hat{y}] - \hat{y}))^2]$$

Сейчас мы представили ошибку как сумму двух частей:

— $(y - \mathbb{E}[\hat{y}])$ — разница между истинным значением и усреднённым предсказанием модели

— $(\mathbb{E}[\hat{y}] - \hat{y})$ — разница между усреднённым предсказанием и конкретным предсказанием

Шаг 2: Раскроем квадрат суммы

$$\mathbb{E}[((y - \mathbb{E}[\hat{y}]) + (\mathbb{E}[\hat{y}] - \hat{y}))^2] = \mathbb{E}[(y - \mathbb{E}[\hat{y}])^2 + 2(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y}) + (\mathbb{E}[\hat{y}] - \hat{y})^2]$$

Шаг 3: Разделим математическое ожидание (по линейности)

У математического ожидания есть одно важное свойство: $\mathbb{E}[a + b + c] = \mathbb{E}[a] + \mathbb{E}[b] + \mathbb{E}[c]$. Применим его:

$$\mathbb{E}[(y - \hat{y})^2] = \mathbb{E}[(y - \mathbb{E}[\hat{y}])^2] + \mathbb{E}[2(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y})] + \mathbb{E}[(\mathbb{E}[\hat{y}] - \hat{y})^2]$$

Шаг 4: Разберёмся со вторым слагаемым

Сосредоточимся на середине:

$$\mathbb{E}[2(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y})]$$

Извлечём константу:

$$2 \cdot \mathbb{E}[(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y})]$$

Вспомним, что y — это истинное значение (константа, не зависит от модели). А $\mathbb{E}[\hat{y}]$ — это тоже константа (мы усредняем по всем возможным моделям). Поэтому $(y - \mathbb{E}[\hat{y}])$ — просто число, которое можно вынести за мат. ожидание:

$$2(y - \mathbb{E}[\hat{y}]) \cdot \mathbb{E}[\mathbb{E}[\hat{y}] - \hat{y}]$$

Теперь посчитаем $\mathbb{E}[\mathbb{E}[\hat{y}] - \hat{y}]$:

$$\mathbb{E}[\mathbb{E}[\hat{y}] - \hat{y}] = \mathbb{E}[\mathbb{E}[\hat{y}]] - \mathbb{E}[\hat{y}] = \mathbb{E}[\hat{y}] - \mathbb{E}[\hat{y}] = 0$$

А соответственно, второе слагаемое полностью обнулится.

$$\mathbb{E}[2(y - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - \hat{y})] = 0$$

Шаг 5: Упростим оставшиеся два члена

Остаются только первый и третий члены:

$$\mathbb{E}[(y - \hat{y})^2] = \mathbb{E}[(y - \mathbb{E}[\hat{y}])^2] + \mathbb{E}[(\mathbb{E}[\hat{y}] - \hat{y})^2]$$

Первый член: $(y - \mathbb{E}[\hat{y}])^2$ — это разница между истинным значением и усреднённым предсказанием, возведённая в квадрат. Когда мы берём математическое ожидание, оно просто остаётся квадратом этой разницы:

$$\mathbb{E}[(y - \mathbb{E}[\hat{y}])^2] = (y - \mathbb{E}[\hat{y}])^2$$

Второй член: $(\mathbb{E}[\hat{y}] - \hat{y})^2$ — это квадрат отклонения предсказания от среднего. Когда мы берём математическое ожидание, это становится дисперсией предсказания:

$$\mathbb{E}[(\mathbb{E}[\hat{y}] - \hat{y})^2] = Var(\hat{y})$$

Шаг 6: Финальная формула

$$\mathbb{E}[(y - \hat{y})^2] = (y - \mathbb{E}[\hat{y}])^2 + \text{Var}(\hat{y})$$

или, обозначив Bias $= \mathbb{E}[\hat{y}] - y$:

$$\mathbb{E}[(y - \hat{y})^2] = \text{Bias}^2 + \text{Variance} + \text{Irreducible Error}$$

И вот, мы наконец-то получили финальную формулу. Это и есть разложение ошибки на смещение и разброс. В дальнейшем мы будем работать именно с ней и объяснять, что каждый компонент означает.

Пояснение к разложению.

Итак, мы получили формулу вида

$$\mathbb{E}[(y - \hat{y})^2] = \text{Bias}^2 + \text{Variance} + \text{Irreducible Error}$$

Давайте разбирать компоненты по очереди.

Смещение

$$Bias = \mathbb{E}[\hat{y}] - y$$

То есть, насколько в среднем наши прогнозы отличаются от реальных ответов. Ещё смещение иногда называют *систематической ошибкой*. Величина означает ошибку, которую модель допускает систематически: неважно, какой размер данных или какого качества данные — модель в любом случае будет ошибаться.

Обычно смещение связывают с простотой модели: если модель слишком простая (представьте себе дерево глубины 1 или 2), то она гарантированно будет *смещена* (т.е. допускать эту систематическую ошибку).

Представьте, что вы строите модель предсказания цены квартиры. Истинная закономерность вот такая:

$$y = 50 * S + 500 * R + 100 * A + \epsilon$$

т.е. некоторая линейная зависимость между площадью, количеством комнат и возрастом здания.

А мы, не зная этого, построили слишком простую модель вида

$$\hat{y} = 40 * S$$

Давайте посмотрим, что будет происходить на разных наборах данных:

1. Квартира: $S = 60, R = 2, A = 10$
   Реальная цена: $y_1 = 50 * 60 + 500 * 2 + 100 * 10 = 5000$
   Предсказание нашей модели: $40 * 60 = 2400$
   Ошибка составляет 2600
2. Квартира: $S = 70, R = 3, A = 15$
   Реальная цена: $y_2 = 50 * 70 + 500 * 3 + 100 * 15 = 6500$
   Предсказание: $40 * 70 = 2800$
   Ошибка составляет 3700
3. Квартира: $S = 50, R = 1, A = 5$
   Реальная цена: $y_3 = 50 * 50 + 500 * 1 + 100 * 5 = 3500$
   Предсказание: $40 * 50 = 2000$
   Ошибка составляет 1500

Итак, среднее предсказание модели:

$$\mathbb{E}[\hat{y}] = \frac{\hat{y_1} + \hat{y_2} + \hat{y_3}}{3} = \frac{7200}{3} = 2400$$

А целевая переменная в среднем:

$$\mathbb{E}[y] = \frac{y_1 + y_2 + y_3}{3} = \frac{15000}{3} = 5000$$

Теперь по формуле считаем смещение:

$$Bias = 2400 - 5000 = -2600$$

Выходит, что построенная нами модель систематически недопредсказывает цену квартиры на 2600 в среднем.

Разброс

$$Variance = \mathbb{E}[(\hat{y} - \mathbb{E}[\hat{y}])^2]$$

Мы измеряем, насколько сильно одно конкретное предсказание отклоняется от всех усреднённых предсказаний. Интуитивно это означает, насколько модель чувствительна к изменениям в данных. Вспомните пример из SVM, когда мы говорили об уверенности классификатора. Если точка стоит рядом с раз-

деляющей гиперплоскостью, то достаточно слегка подвинуть гиперплоскость, как класс на этом объекте изменится. Именно такая интуиция применима к понятию разброса.

В то время, как смещение связывают с простотой модели, разброс наоборот, со сложностью модели. Попытайтесь задуматься: если модель слишком сильно улавливает какие-то зависимости в данных, то если расставить эти объекты на плоскости немного иным образом (т.е. поменять выборку на похожую), то результат сильно просядет. Это именно тот эффект, который мы наблюдаем при переобучении модели.

Давайте предположим, что по аналогии со смещением, у нас есть модель, которая трижды обучена на разных датасетах (квартира из центра города, из пригорода и смешанные). Их предсказания: $\hat{y_1} = 5500, \hat{y_2} = 4200, \hat{y_3} = 4800$. Соответственно,

$$\mathbb{E}[\hat{y}] = \frac{\hat{y_1} + \hat{y_2} + \hat{y_3}}{3} = \frac{14500}{3} \approx 4833$$

Посчитаем отклонение каждого конкретного прогноза от среднего:

$$\hat{y_1} - \mathbb{E}[\hat{y}] = 5500 - 4833 = 667$$

$$\hat{y_2} - \mathbb{E}[\hat{y}] = 4200 - 4833 = -633$$

$$\hat{y_3} = \mathbb{E}[\hat{y}] = 4800 - 4833 = -33$$

Ну и квадраты отклонений:

$$(\hat{y_1} - \mathbb{E}[\hat{y}])^2 = 444,889$$

$$\hat{y_2} - \mathbb{E}[\hat{y}] = 400,689$$

$$\hat{y_3} - \mathbb{E}[\hat{y}] = 1,089$$

Таким образом, в среднем разброс составляет

$$\frac{846,667}{3} \approx 282,222$$

Как мы видим, для разных типов квартир (из центра, смешанные и т.д.) получаются сильно разные ответы. Это и есть разброс модели: небольшие изменения в наборе данных сильно влияют на работу модели, что похоже на переобучение модели.

Но какое нам дело, что там на других наборах данных? На нашем работает — ну и хорошо, так ведь? Нет, не так ведь. Дело в том, что в рамках задачи данные, например, могут поступать ежедневно: при том же прогнозе погоды. В таком случае крайне важно, чтобы модель не выучивала каждый набор данных, а искала какие-то общие закономерности (это и есть обобщающая способность модели).

Внимательный читатель мог заметить интересный парадокс: выходит, если мы упрощаем модель, то ошибка увеличивается, но если мы усложняем модель — ошибка тоже увеличивается? На самом деле, так оно и есть, и вскоре мы в этом убедимся. В машинном обучении главное находить компромисс между ошибкой, которая возникает из-за смещения, и ошибкой, которая возникает из-за разброса. Этот компромисс ещё называют Bias-variance tradeoff.

Шум

У шума нет как таковой формулы. Вспомните из ранее описанной формулировки, что из себя представлял ϵ. Так вот, этот эпсилон и есть шум — это некоторая ошибка, на которую невозможно повлиять и её никак нельзя уменьшить. Резюмируя — любая модель будет допускать ошибку, которую невозможно исправить и модель будет гарантированно ошибаться. В наших силах лишь сделать эту ошибку как можно меньше, но убрать её полностью — невозможно.

Дополнительное пояснение к смещению и разбросу

Довольно популярной интерпретацией смещения и разброса является следующее изображение:

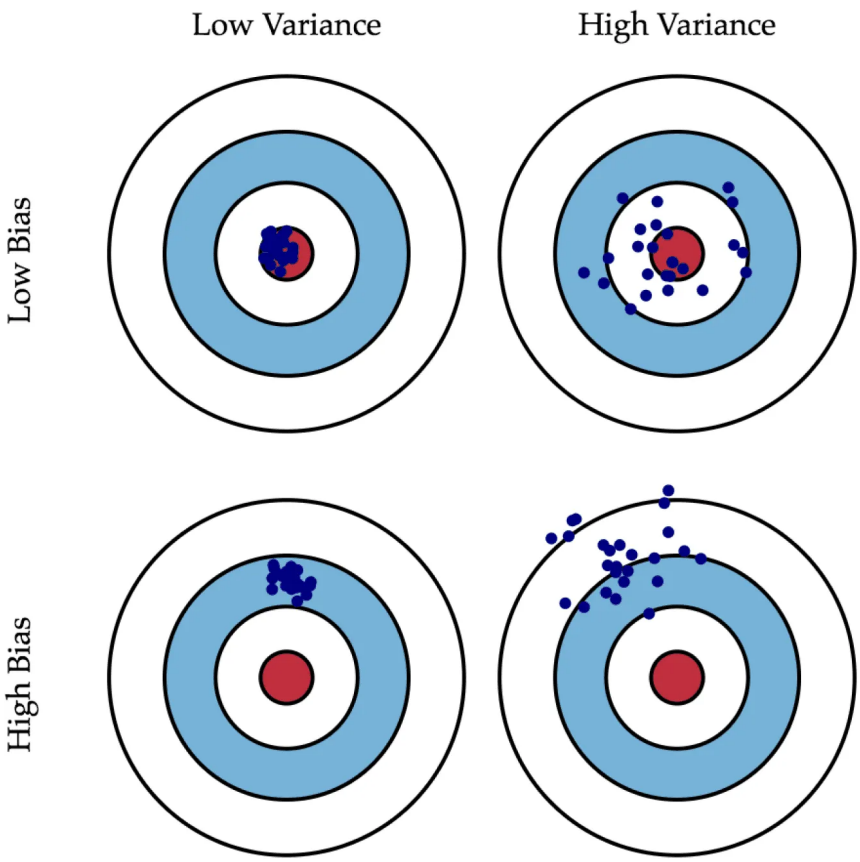

При низком разбросе, но высоком смещении, мы видим, что выстрелы кучные, но все мимо — это и есть недообучение. Наша модель не слишком неадекватная, но при этом систематически «попадает» не туда.

При высоком разбросе, но низком смещении, мы вроде как «попадаем» туда, но наша «стрельба», мягко скажем, не самая точная. Это объясняется переобучением: модель слишком сильно подстраивается под закономерности в данных, после чего не способна показать себя хорошо на новых данных.

В случае высокого смещения и высокого разброса, модель просто неадекватная. Модель выдаёт слишком разное, но при этом и близко не в той области, где должна. Обычно это свидетельствует о том, что модель поломана, то есть выдаёт абсолютно непредсказуемые и неинтерпретируемые значения.

Визуализация смещения и разброса

Давайте рассмотрим деревья на разных наборах данных, и будем постепенно увеличивать их максимальную глубину (напомним, что за это отвечает параметр max_depth:

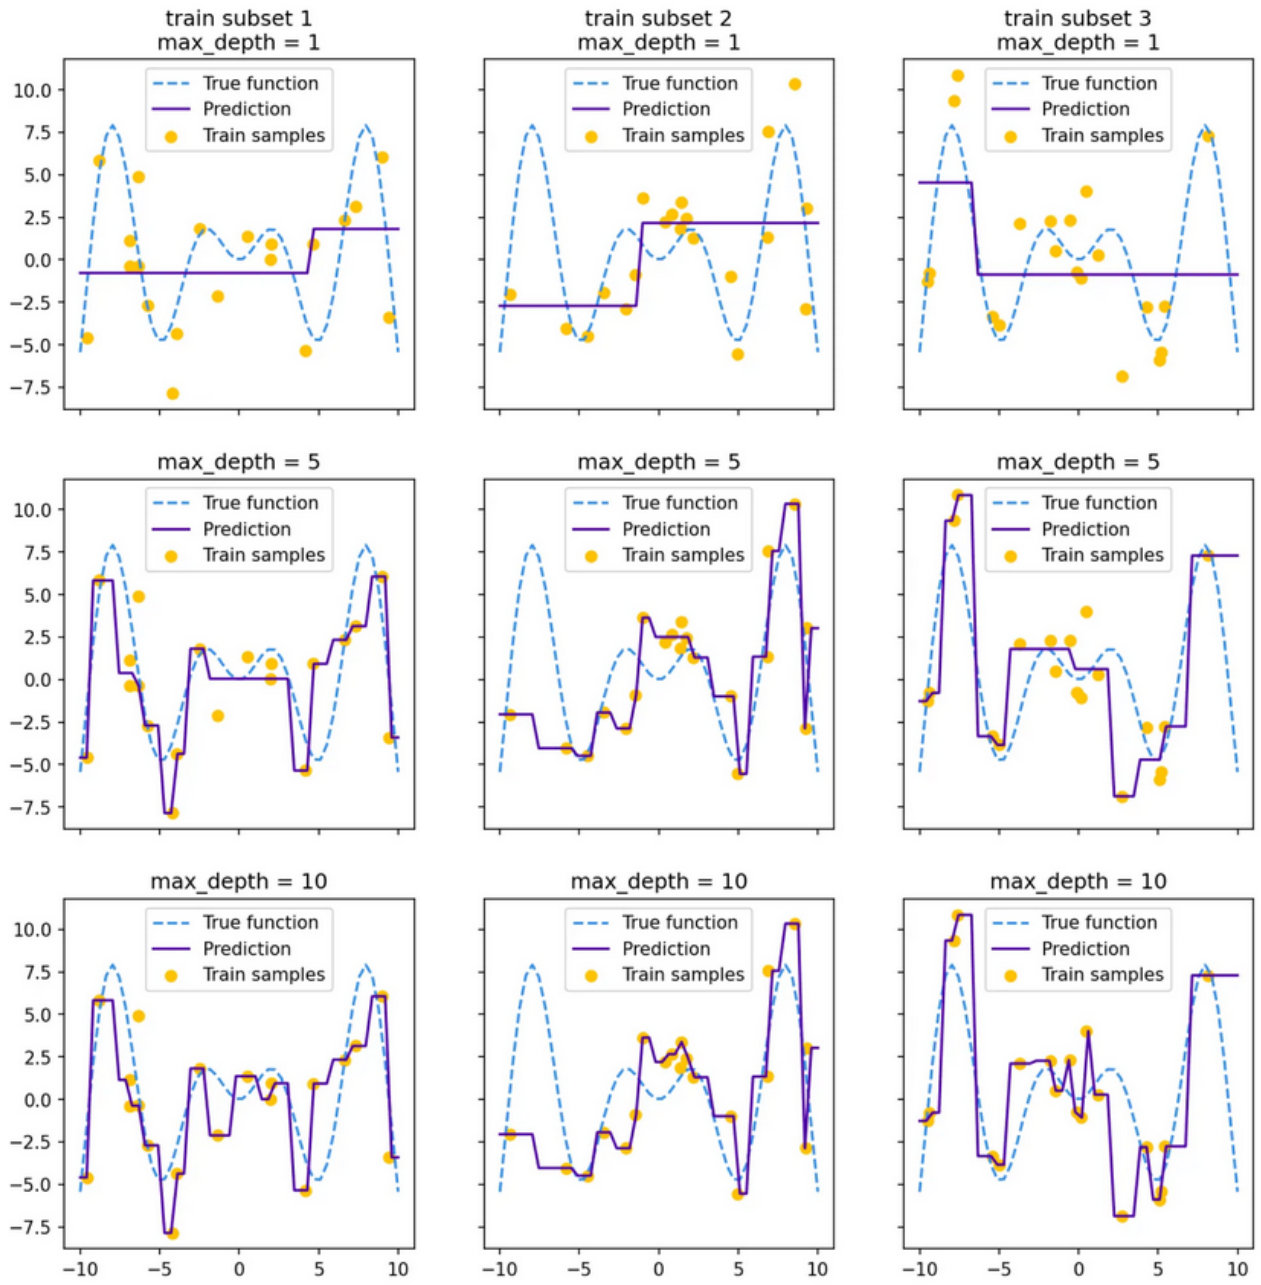

Как мы видим, при глубине 1, наши деревья совсем ничего не улавливают в данных, а их прогнозы происходят где-то мимо — это свидительствует о высоком смещении.

Давайте рассмотрим другой граничный случай, при глубине 10. В таком случае, деревья слишком сильно адаптируются под данные. Проведём мысленный эксперимент: дорисуем ещё похожие точки и с лёгкостью убедимся, что

модель многовероятно будет сильно ошибаться на них. Это и есть переобучение, которое является следствием из высокого разброса.

При глубине 5 всё работает так, как мы и ожидаем — модель достаточно обучена, чтобы находить закономерности, и не слишком переобучена, чтобы не уметь предсказывать на новых данных.

Управление смещением и разбросом для оптимизации моделей машинного обучения

На самом деле, можно строить следующие параллели:

— Как мы боремся с недообучением — ровно такие же методы мы применяем для борьбы с высоким смещением;
— Аналогично с высоким разбросом и переобученим.

Т.е. для «подавления» роста смещения можно использовать уже известные регуляризации, например. Или, как вариант, можно разбить исходную выборку на 2: на одной из выборок обучаться, а на другой — проверять качество модели. Если на второй выборке качество плохое — модель переобучена.

Кросс-валидация и метод KFold: обеспечение надёжности оценки моделей

Однако у метода, который мы рассмотрели ранее, есть одна большая проблема — разбиение происходит случайным образом, и соответственно, мы не можем гарантировать, что данные на тестовой выборке (на которой проверяем качество модели) модель вообще будет в состоянии обработать. А что если первый, тренировочный набор содержит вообще непохожие примеры?

Соответственно, мы сильно зависим от случайности этого разбиения. Но как можно этого избежать?

Техника, которая позволяет получить более объективную оценку, называется KFold. Её алгоритм заключается в следующем: исходный набор данных случайным образом разбивается на K равных по размеру частей, называемых фолдами (folds). Далее процесс обучения и оценки повторяется K раз. На каждой итерации один из K фолдов по очереди выступает в роли тестовой выборки (validation fold), а остальные $(K-1)$ фолды объединяются в обучающую выборку. Модель обучается на $K-1$ фолдах, а потом тестируется на одном фолде. Так повторяется до тех пор, пока не будут рассмотрены все такие разбиения данных на K фолдов.

Результатом работы алгоритма является массив из K оценок качества. Итоговая оценка модели вычисляется как среднее арифметическое этих K значений, а её стабильность можно оценить по стандартному отклонению.