Unsupervised Learning

&&

Харитон Пицик

2026-03-13

Клуб машинного обучения

Recap: Supervised Learning

&&

Recap: Supervised Learning

&&

- Дана выборка объектов $\mathbb{X}$ с целевой переменной $\mathbb{Y}$;

Recap: Supervised Learning

&&

- Дана выборка объектов $\mathbb{X}$ с целевой переменной $\mathbb{Y}$;
- Необходимо построить алгоритм, предсказывающий целевую переменную: $a : \mathbb{X} \to \mathbb{Y}$;

Recap: Supervised Learning

&&

- Дана выборка объектов $\mathbb{X}$ с целевой переменной $\mathbb{Y}$;
- Необходимо построить алгоритм, предсказывающий целевую переменную: $a : \mathbb{X} \to \mathbb{Y}$;
- Задачи разделяются на регрессию ($y \in \mathbb{R}$) и классификацию ($y \in \{0, 1, ..., C\}$);

Recap: Supervised Learning

&&

- Дана выборка объектов $\mathbb{X}$ с целевой переменной $\mathbb{Y}$;
- Необходимо построить алгоритм, предсказывающий целевую переменную: $a : \mathbb{X} \to \mathbb{Y}$;
- Задачи разделяются на регрессию ($y \in \mathbb{R}$) и классификацию ($y \in \{0, 1, ..., C\}$);
- Bias-variance tradeoff не позволяет делать модели слишком сложными или слишком простыми;

Recap: Supervised Learning

&&

- Дана выборка объектов $\mathbb{X}$ с целевой переменной $\mathbb{Y}$;
- Необходимо построить алгоритм, предсказывающий целевую переменную: $a : \mathbb{X} \to \mathbb{Y}$;
- Задачи разделяются на регрессию ($y \in \mathbb{R}$) и классификацию ($y \in \{0, 1, ..., C\}$);
- Bias-variance tradeoff не позволяет делать модели слишком сложными или слишком простыми;
- Бустинги достаточно хорошо справляются с обеими задачами.

Unsupervised Learning

Clustering

Clustering task

&&

Задача кластеризации состоит в том, чтобы разбить объекты из $\mathbb{X}$ на наиболее похожие группы (кластеры) по какому-либо из (не обязательно явных) критериев.

Задача кластеризации состоит в том, чтобы разбить объекты из $\mathbb{X}$ на наиболее похожие группы (кластеры) по какому-либо из (не обязательно явных) критериев.

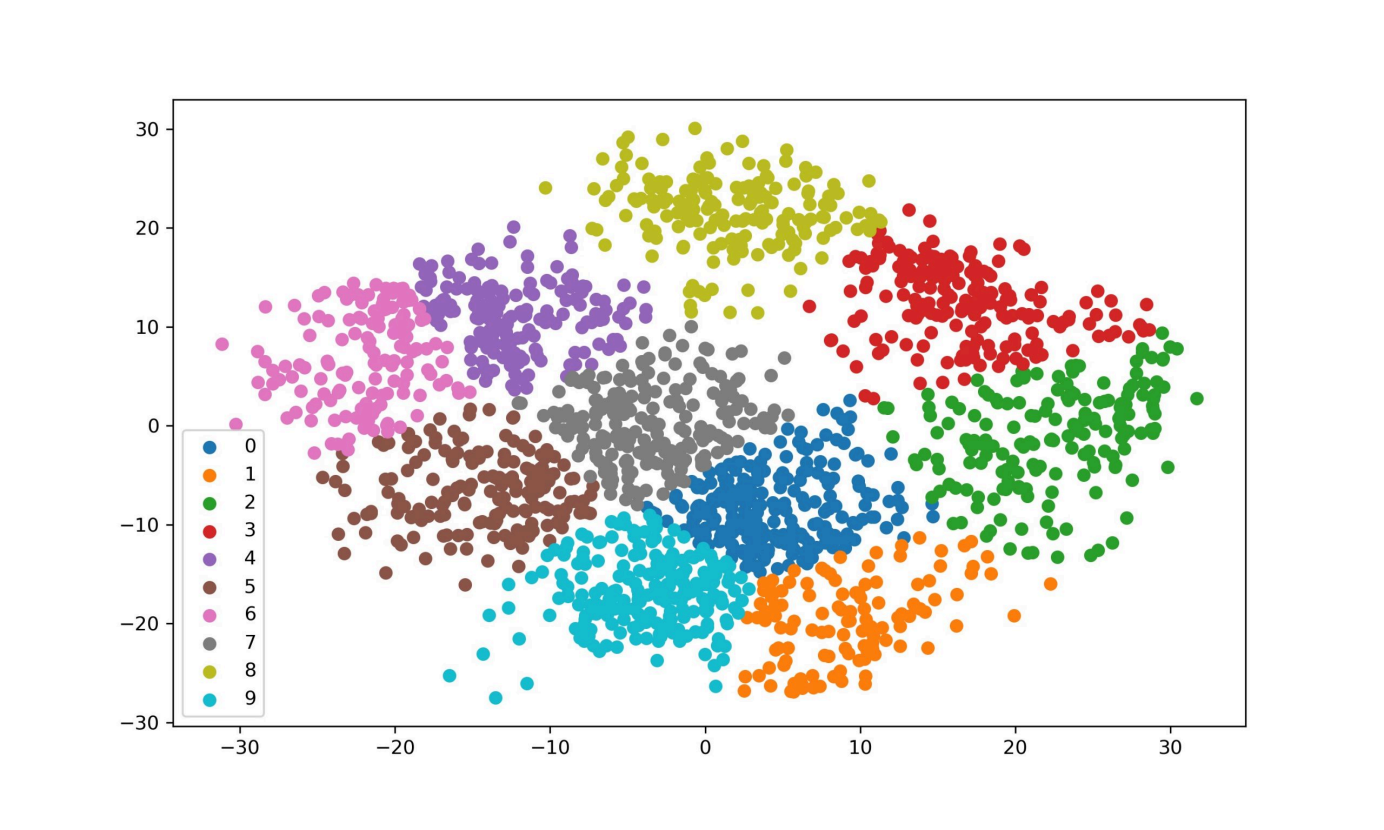

Clustering task

&&

Выходит, что нужно построить $a : \mathbb{X} \to \{0, 1 \ldots K\}$, при этом $a(x_i) = a(x_j) \Leftrightarrow x_i$ “похож” на x_j.

Проблемы:

Выходит, что нужно построить $a : \mathbb{X} \to \{0, 1 \ldots K\}$, при этом $a(x_i) = a(x_j) \Leftrightarrow x_i$ “похож” на x_j.

Проблемы:

- Что такое K?

Выходит, что нужно построить $a : \mathbb{X} \to \{0, 1 \ldots K\}$, при этом $a(x_i) = a(x_j) \Leftrightarrow x_i$ “похож” на x_j.

Проблемы:

- Что такое K?
- Что значит “похожи”? Как модель понимает это слово?

Метрики качества

Внутрикластерное расстояние. &&

У каждого кластера есть центр, обозначим за c_k. Тогда мы можем посчитать расстояния внутри каждого класса:

Внутрикластерное расстояние. &&

У каждого кластера есть центр, обозначим за c_k. Тогда мы можем посчитать расстояния внутри каждого класса:

$$\frac{1}{n}\sum_{k=1}^{K}\sum_{i=1}^{\ell}[a(x_i) == k]\rho(x_i, c_k)$$

Межкластерное расстояние. &&

Также можно взять во внимание расстояние между двумя разными объектами, которые находятся в разных кластерах:

Межкластерное расстояние. &&

Также можно взять во внимание расстояние между двумя разными объектами, которые находятся в разных кластерах:

$$\sum_{i,j=1,i\neq j}^{\ell} \left[a(x_i) \neq a(x_j)\right] \rho(x_i, x_j)$$

Метрическая кластеризация

Алгоритм K-Means является представителем алгоритмов метрической кластеризации. В качестве параметра принимает K – количество центров.

Сам алгоритм:

Алгоритм K-Means является представителем алгоритмов метрической кластеризации. В качестве параметра принимает K – количество центров.

Сам алгоритм:

0. Случайно инициализируем K центров: $c_1, c_2, ..., c_K$;

Алгоритм K-Means является представителем алгоритмов метрической кластеризации. В качестве параметра принимает K – количество центров.

Сам алгоритм:

0. Случайно инициализируем K центров: $c_1, c_2, ..., c_K$;
1. Фиксируем центры, ищем оптимальное расположение объектов по кластерам: $\sum_{k=1}^{K} \sum_{i=1}^{\ell} [a(x_i) == k] \rho(x_i, c_k) \to \min_a$;

Алгоритм K-Means является представителем алгоритмов метрической кластеризации. В качестве параметра принимает K – количество центров.

Сам алгоритм:

0. Случайно инициализируем K центров: $c_1, c_2, ..., c_K$;
1. Фиксируем центры, ищем оптимальное расположение объектов по кластерам: $\sum_{k=1}^{K} \sum_{i=1}^{\ell} [a(x_i) == k] \rho(x_i, c_k) \to \min_a$;
2. Фиксируем полученное расположение объектов, уже на их основе ищем оптимальные центры: $\sum_{k=1}^{K} \sum_{i=1}^{\ell} [a(x_i) == k] \rho(x_i, c_k) \to \min_{c_1, ... c_k}$;

Алгоритм K-Means является представителем алгоритмов метрической кластеризации. В качестве параметра принимает K – количество центров.

Сам алгоритм:

0. Случайно инициализируем K центров: $c_1, c_2, ..., c_K$;
1. Фиксируем центры, ищем оптимальное расположение объектов по кластерам: $\sum_{k=1}^{K} \sum_{i=1}^{\ell} [a(x_i) == k] \rho(x_i, c_k) \to \min_a$;
2. Фиксируем полученное расположение объектов, уже на их основе ищем оптимальные центры: $\sum_{k=1}^{K} \sum_{i=1}^{\ell} [a(x_i) == k] \rho(x_i, c_k) \to \min_{c_1, ... c_k}$;
3. Повторяем шаги 1, 2 до сходимости.

Оптимальным решением является средний объект в кластере (если используется евклидова метрика):

Оптимальным решением является средний объект в кластере (если используется евклидова метрика):

$$c_k = \frac{1}{\sum_{i=1}^{\ell}[a(x_i) == k]} \sum_{i=1}^{\ell}[a(x_i) == k]x_i$$

Таким образом, K-Means будет уместен в ситуации, когда уместна евклидова метрика.

Таким образом, K-Means будет уместен в ситуации, когда уместна евклидова метрика. Иначе говоря, K-Means не справится со следующей задачей:

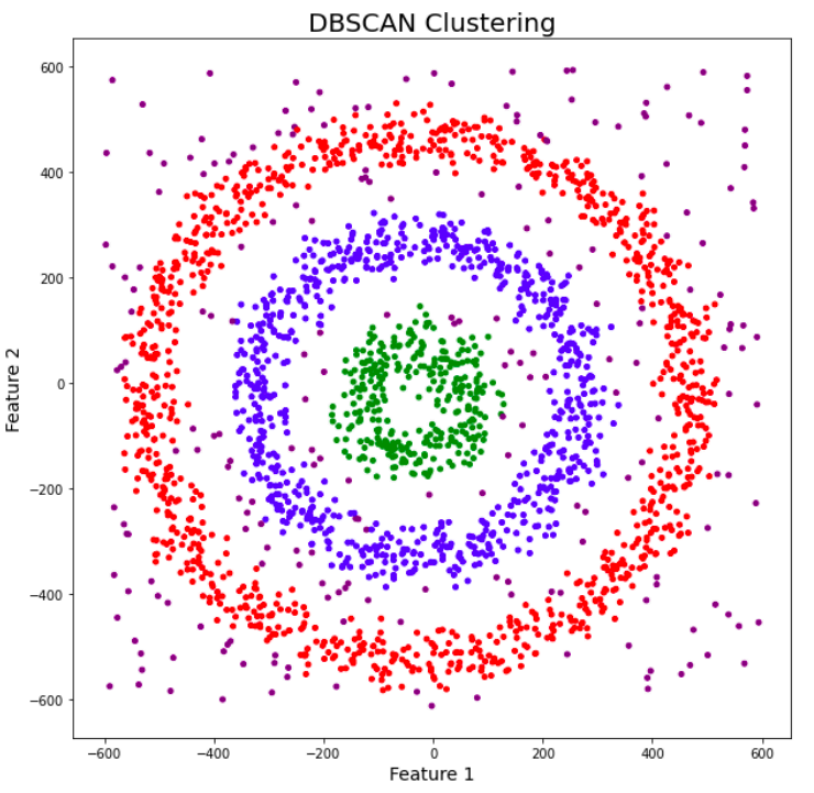

Как подобрать K?

Мы предполагаем, что при наращивании K, в какой-то момент его значение перестаёт быть столь эффективным в сравнении с предыдущим. Именно одну из первых таких точек будем считать оптимальной:

Elbow method

&&

Мы предполагаем, что при наращивании K, в какой-то момент его значение перестаёт быть столь эффективным в сравнении с предыдущим. Именно одну из первых таких точек будем считать оптимальной:

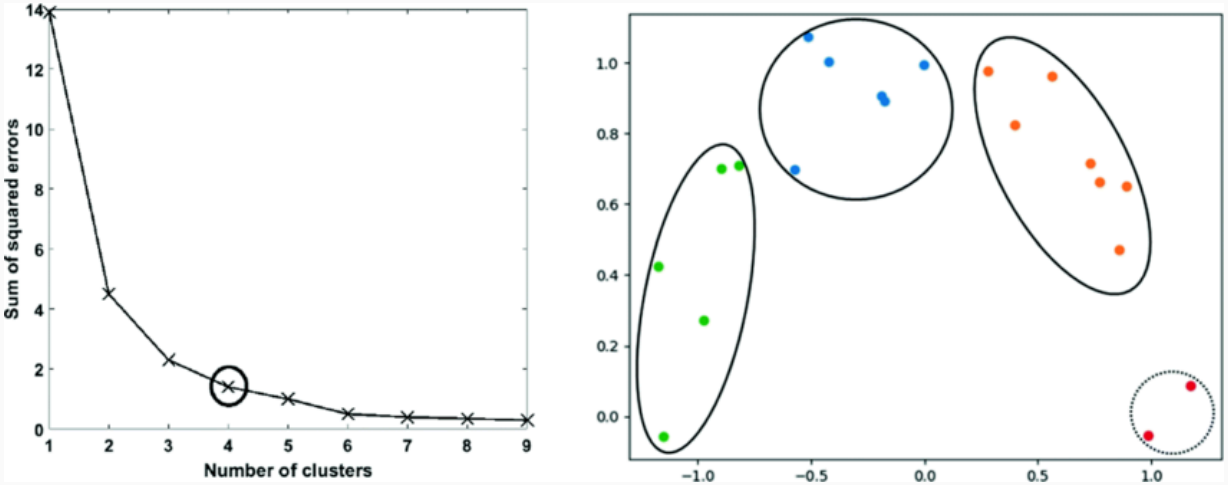

Какие ещё бывают методы?

Какие ещё бывают методы?

&&

- Плотностные;

Какие ещё бывают методы?

&&

- Плотностные;
- Иерархические;

Какие ещё бывают методы?

&&

- Плотностные;
- Иерархические;
- Графовые.

Dimensionality Reduction

Зачем?

&&

Основное предположение заключается в том, что в некоторых случаях размерность данных может быть избыточной (иметь слишком много признаков). Это может привести к:

Основное предположение заключается в том, что в некоторых случаях размерность данных может быть избыточной (иметь слишком много признаков). Это может привести к:

- Понижению качества;

Зачем?

&&

Основное предположение заключается в том, что в некоторых случаях размерность данных может быть избыточной (иметь слишком много признаков). Это может привести к:

- Понижению качества;
- Увеличению стоимости вычислений;

Основное предположение заключается в том, что в некоторых случаях размерность данных может быть избыточной (иметь слишком много признаков). Это может привести к:

- Понижению качества;
- Увеличению стоимости вычислений;
- Усложнению интерпретируемости результатов.

Пример: MNIST

&&

Для примера рассмотрим набор данных рукописных цифр – MNIST. Он содержит изображения рукописных цифр от 0 до 9, предполагается для разработки модели для задачи классификации.

Пример: MNIST

&&

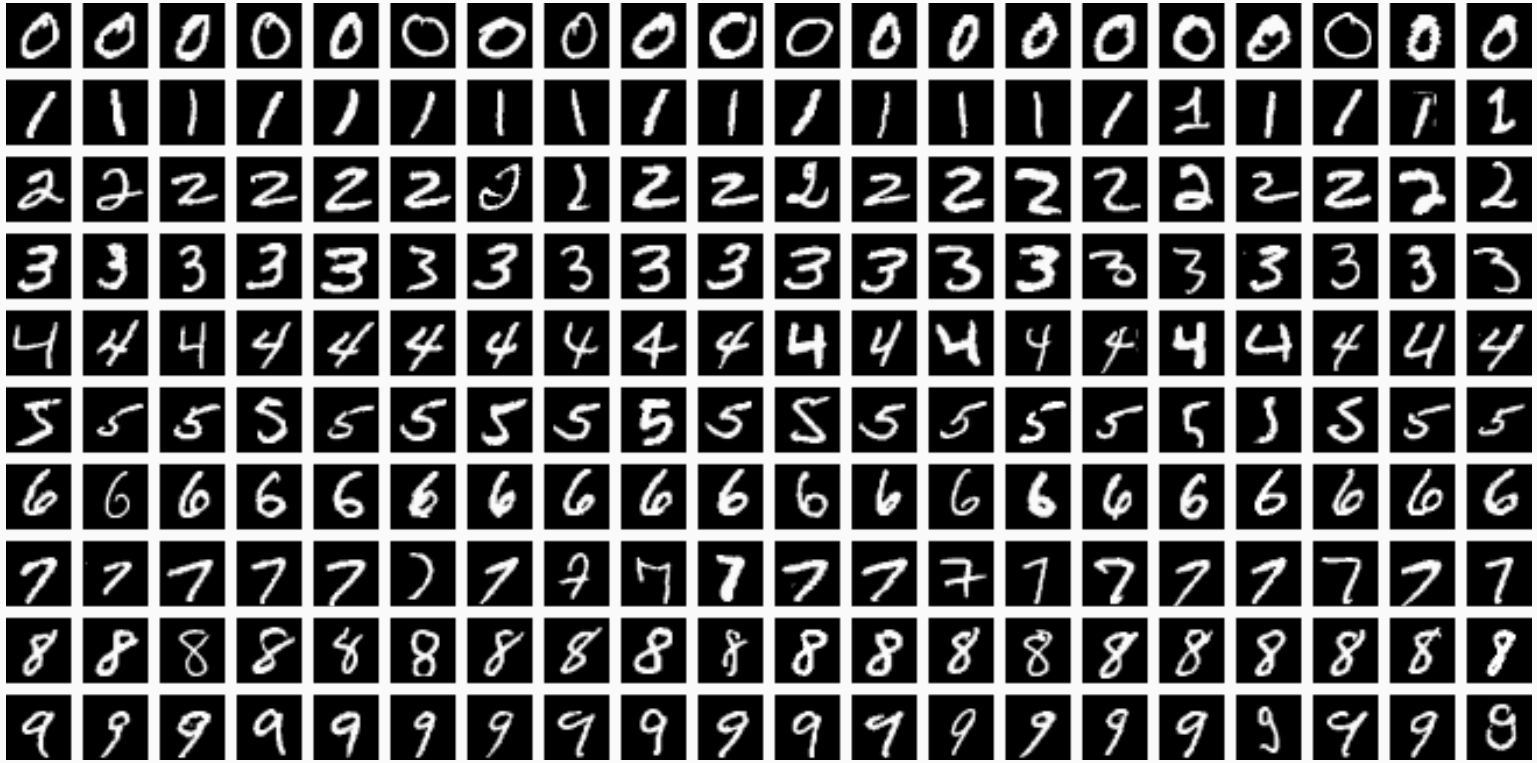

Пример: MNIST

&&

Для примера рассмотрим набор данных рукописных цифр – MNIST. Он содержит изображения рукописных цифр от 0 до 9, предполагается для разработки модели для задачи классификации.

Каждое изображение представляет из себя матрицу 28×28 пикселей. Соответственно, каждый объект лежит вот в таком пространстве...

Пример: MNIST

&&

Для примера рассмотрим набор данных рукописных цифр – MNIST. Он содержит изображения рукописных цифр от 0 до 9, предполагается для разработки модели для задачи классификации.

Каждое изображение представляет из себя матрицу 28×28 пикселей. Соответственно, каждый объект лежит вот в таком пространстве...

$$x \in \mathbb{R}^{28 \times 28} \Rightarrow x \in \mathbb{R}^{784}$$

Понижение размерности MNIST

&&

Давайте в качестве эксперимента постараемся представлять объекты не в пространстве $\mathbb{R}^{784}$, а, например, $\mathbb{R}^2$, а результаты постараемся нарисовать на плоскости.

Давайте в качестве эксперимента постараемся представлять объекты не в пространстве $\mathbb{R}^{784}$, а, например, $\mathbb{R}^2$, а результаты постараемся нарисовать на плоскости.

Для этих целей воспользуемся **методом главных компонент (Principal Component Analysis, PCA)** – одним из основных методов понижения размерности.

Алгоритм PCA

&&

0. Стандартизируем наши данные: $x_{new} = \frac{x-a}{\sigma}$;

Алгоритм PCA

&&

0. Стандартизируем наши данные: $x_{new} = \frac{x-a}{\sigma}$;
1. Построим ковариационную матрицу (Covariance matrix);

Алгоритм PCA

&&

0. Стандартизируем наши данные: $x_{new} = \frac{x-a}{\sigma}$;
1. Построим ковариационную матрицу (Covariance matrix);
2. У каждого оторабжение есть собственные векторы, которые описывают какую-то часть вариативности данных, и их собственные значения;

Алгоритм PCA

&&

0. Стандартизируем наши данные: $x_{new} = \frac{x-a}{\sigma}$;
1. Построим ковариационную матрицу (Covariance matrix);
2. У каждого оторабжение есть собственные векторы, которые описывают какую-то часть вариативности данных, и их собственные значения;
3. Полученные векторы будем ранжировать в зависимости от соответствующего собственного значения, а сами векторы будем интерпретировать как наиболее полезные направления (направления, которые отражают наибольшую суть данных);

Алгоритм PCA

&&

0. Стандартизируем наши данные: $x_{new} = \frac{x-a}{\sigma}$;
1. Построим ковариационную матрицу (Covariance matrix);
2. У каждого оторабжение есть собственные векторы, которые описывают какую-то часть вариативности данных, и их собственные значения;
3. Полученные векторы будем ранжировать в зависимости от соответствующего собственного значения, а сами векторы будем интерпретировать как наиболее полезные направления (направления, которые отражают наибольшую суть данных);
4. Сохраняем полученные размерности, алгоритм завершён.

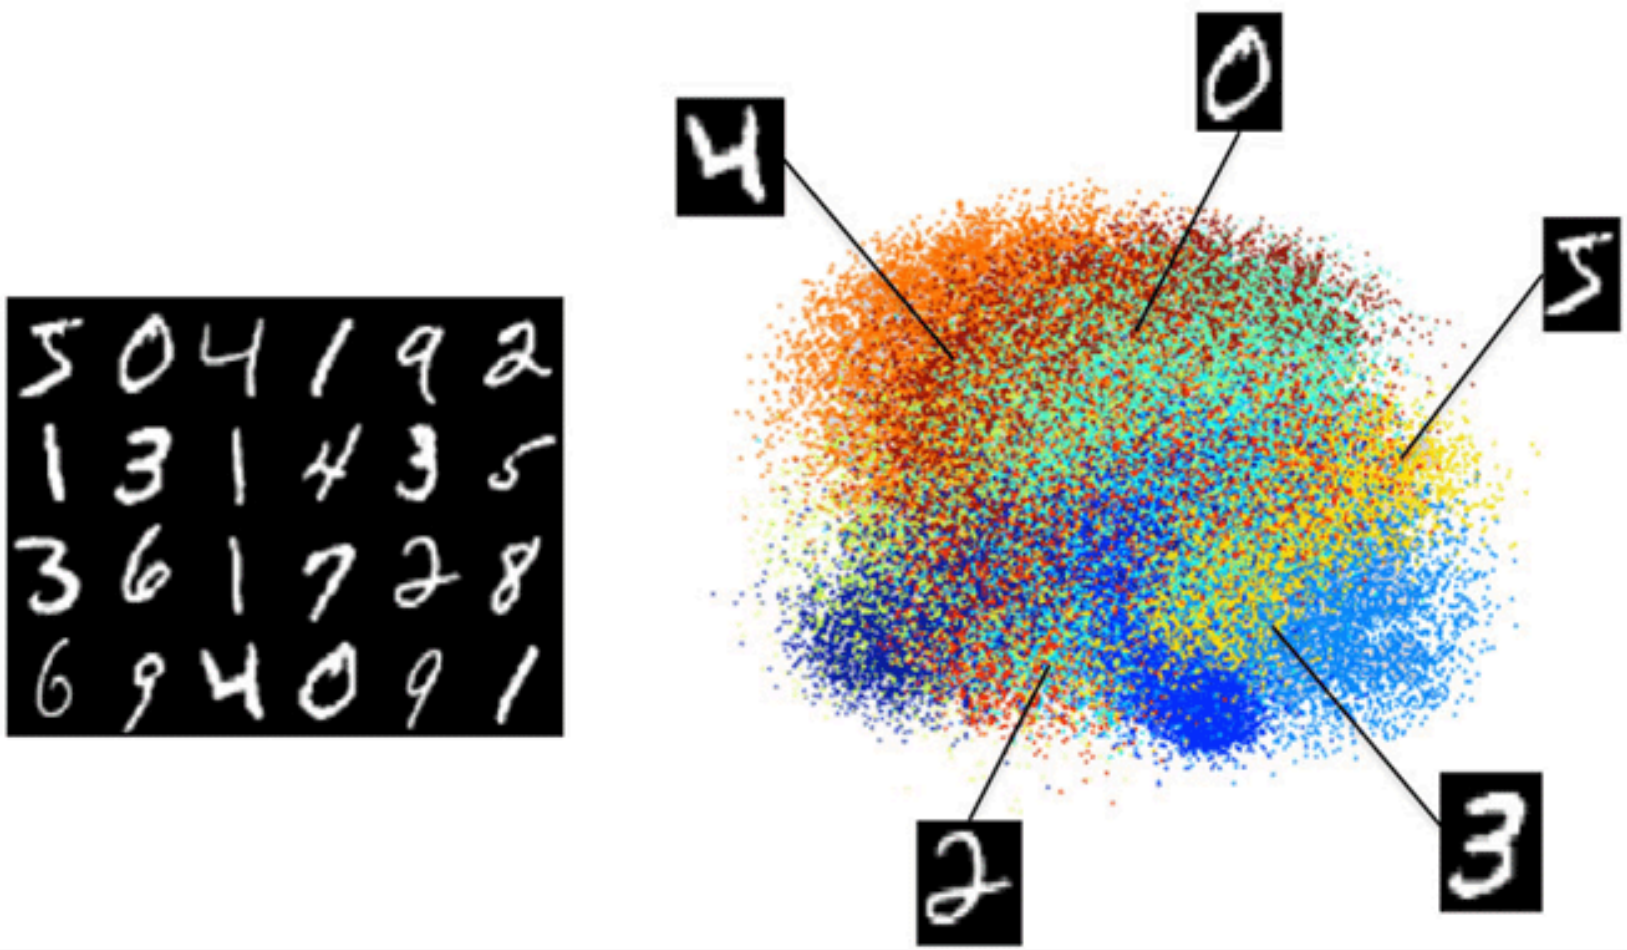
4
0
5
2
3

Какие методы ещё бывают?

Какие методы ещё бывают?

&&

- t-SNE;

Какие методы ещё бывают?

- t-SNE;
- UMAP;

Какие методы ещё бывают?

&&

- t-SNE;
- UMAP;
- Autoencoders;

Какие методы ещё бывают?

- t-SNE;
- UMAP;
- Autoencoders;
- ...